Análisis de comorbilidades en pacientes positivos a COVID-19 mediante herramientas de Big Data

Martínez Jiménez Saúl Jacob

1. Introducción

La pandemia de COVID-19 generó grandes volúmenes de información relacionada con las características demográficas, clínicas y epidemiológicas de los pacientes atendidos en México. El análisis de estos datos permite identificar patrones asociados con la presencia de enfermedades preexistentes, hábitos y defunciones registradas entre los casos confirmados.

El presente trabajo se basó en el conjunto de datos abiertos de COVID-19 correspondiente a México durante 2022. El archivo original contenía aproximadamente 40 variables y millones de registros, por lo que fue necesario aplicar técnicas de procesamiento de datos a gran escala. Después de la preparación del conjunto de datos se obtuvieron 17,311,019 registros utilizables, de los cuales 6,522,993 correspondieron a casos positivos de COVID-19.

El objetivo principal fue analizar la frecuencia de las comorbilidades en los pacientes positivos y estudiar su relación con las defunciones registradas. De manera complementaria, se evaluó el rendimiento de distintos formatos de almacenamiento y entornos de ejecución, comparando archivos CSV y Parquet, así como Google Colab y un entorno local.

El uso de técnicas de Big Data fue necesario debido al tamaño del conjunto de datos. La lectura, filtrado, transformación y agrupación de más de 17 millones de registros requiere herramientas capaces de realizar operaciones eficientes y administrar adecuadamente los recursos disponibles. Para este propósito se utilizaron Python, Polars, Google Colab, un entorno local y el formato Parquet.

2. Preparación de los datos

2.1 Selección de variables

Como primer paso se seleccionaron las columnas necesarias para el análisis de los casos positivos, las comorbilidades, el tabaquismo, la entidad federativa, la edad y la condición de defunción.

La reducción de columnas permitió disminuir la cantidad de información que debía mantenerse en memoria y concentrar el análisis únicamente en las variables relacionadas con los objetivos del estudio.

2.2 Limpieza y transformación

Durante la preparación de los datos se revisaron los tipos de datos, los valores especiales utilizados por el conjunto original y los registros que no podían interpretarse correctamente.

Los valores codificados como desconocidos, no especificados o no aplicables no deben interpretarse automáticamente como ausencia de una enfermedad. Por esta razón, su tratamiento debe diferenciarse de los valores que representan explícitamente una respuesta negativa.

También se verificó que las columnas utilizadas en el análisis conservaran una estructura consistente antes de realizar las agrupaciones y generar el archivo final.

2.3 Manejo de la fecha 9999-99-99

La columna FECHA_DEF utiliza el valor 9999-99-99 como un código especial para indicar que no se registró una defunción. Este valor no representa una fecha real y, por lo tanto, no se convirtió directamente a un tipo de dato de fecha.

Para generar la variable de defunción se utilizó la siguiente interpretación:

- Si FECHA_DEF era igual a 9999-99-99, el paciente se clasificó como no fallecido.
- Si FECHA_DEF contenía una fecha válida, el paciente se clasificó como fallecido.

De esta manera se creó una variable binaria que permitió calcular la proporción de defunciones entre los casos positivos.

Debe aclararse que 9999-99-99 no fue considerado un dato corrupto ni se sustituyó mediante la media o la moda, ya que funciona como un código definido dentro del conjunto de datos.

2.4 Conversión de CSV a Parquet

El conjunto de datos original se encontraba en formato CSV. Aunque este formato es ampliamente compatible, requiere interpretar nuevamente los tipos de datos cada vez que se realiza una lectura y no está optimizado para consultar únicamente determinadas columnas.

Después de limpiar y transformar la información, el conjunto resultante se almacenó en formato Parquet. Parquet es un formato columnar que conserva el esquema de los datos y permite leer únicamente las columnas necesarias para cada operación.

La conversión tuvo dos propósitos. El primero fue obtener un archivo preparado y reutilizable para el análisis. El segundo fue evaluar si el formato Parquet ofrecía ventajas de rendimiento frente al archivo CSV.

3. Metodología del análisis

3.1 Identificación de casos positivos

A partir de la columna CLASIFICACION_FINAL, se tomaron los registros con valores 1, 2 o 3 que fueron considerados casos positivos de COVID-19:

El universo principal del análisis estuvo formado únicamente por los registros clasificados como positivos. Esto permitió que todas las frecuencias y proporciones se calcularan sobre la misma población de estudio.

3.2 Clasificación de comorbilidades y hábitos

Las enfermedades o comorbilidades consideradas fueron:

- Diabetes.
- Enfermedad pulmonar obstructiva crónica.
- Asma.
- Hipertensión.
- Enfermedad cardiovascular.
- Obesidad.
- Enfermedad renal crónica.
- Otras comorbilidades.
- Inmunosupresión.

El hábito considerado fue:

- Tabaquismo.

La inmunosupresión se incluyó dentro del grupo de enfermedades debido a que representa una condición clínica que afecta la respuesta inmunitaria del paciente. El tabaquismo se mantuvo por separado porque se considera un hábito o factor de exposición y no una enfermedad.

La neumonía no fue incluida como comorbilidad debido a que puede presentarse como una manifestación o complicación del propio proceso infeccioso, en lugar de representar necesariamente una enfermedad preexistente.

4. Resultados

La evaluación de rendimiento se realizó de manera independiente al análisis epidemiológico. Su objetivo no fue producir diferentes resultados clínicos, sino medir el tiempo y los recursos necesarios para procesar el mismo conjunto de datos bajo diferentes condiciones.

En todas las pruebas se procuró mantener constantes:

- El conjunto de datos.
- Las columnas utilizadas.
- Los filtros aplicados.

- Las agrupaciones realizadas.
- El código de procesamiento.
- La cantidad esperada de casos positivos.

4.1 Experimento A: CSV frente a Parquet

El Experimento A comparó CSV y Parquet en Google Colab mediante cuatro operaciones: lectura del universo positivo, frecuencia de enfermedades y hábito, mortalidad por variable y mortalidad por estado. Además, comprobó que ambos formatos produjeran los mismos resultados analíticos.

Se midieron operaciones representativas del análisis, como:

- Carga del archivo.
- Selección de columnas.
- Filtrado de casos positivos.
- Conteo o agrupación de comorbilidades.
- Cálculo del tiempo total de procesamiento.

El entorno se mantuvo constante para que las diferencias observadas pudieran atribuirse principalmente al formato de almacenamiento.

La tabla muestra los tiempos de las operaciones en segundos para el dataset en formato CSV v Parquet

Tabla 1 Tiempos de operaciones usando el dataset en CSV y Parquet

operacion	CSV	Parquet	aceleracion_parquet_x	reduccion_tiempo_porcentaje
Frecuencia de enfermedades, trastornos y habitos	14.838918888000008	0.8229562579999765	18.031236464575866	94.45406862715933
Lectura	15.536184993000006	0.9234156269999403	16.824693603545665	94.05635535740599
Mortalidad por enfermedad, trastorno o habito	20.615468925999972	6.474826887999825	3.183941328872834	68.59238608036739
Mortalidad por estado	11.299205764999897	0.81693435	13.831228657060862	92.76998432464279

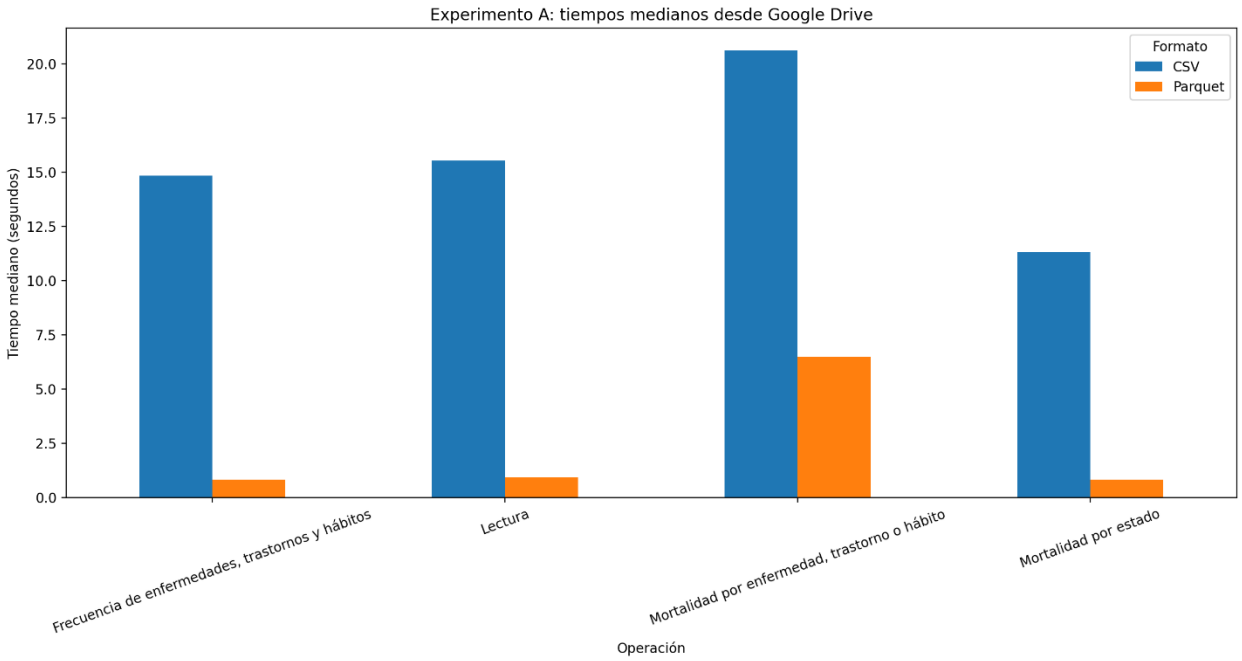


Figura 1 grafica de tiempos de operaciones CSV vs Parquet

4.2 Experimento B: Colab frente a entorno local

En el segundo experimento se utilizó el mismo archivo Parquet y se ejecutaron las mismas operaciones en Google Colab primero usando el entorno y recursos asignados por Google y en la segunda usando un entorno local usando los recursos locales

En este caso se mantuvo constante el formato para estudiar el efecto del entorno de ejecución.

La tabla muestra los tiempos de las operaciones usando el entorno de Google y con recursos de Google y los recursos locales

Tabla 2 tiempos de ejecucion recursos google y locales

operacion	mediana_colab_segundos	media_colab_segundos	minimo_colab_segundos	maximo_colab_segundos	mediana_local_segundos	media_local_segundos	minimo_local_segundos	maximo_local_segundos	aceleracion_local_x	reduccion_porcentual_tiempo	interpretacion
Lectura y materializacion	1.07941043100	0.96988274199	0.66964	1.160602	0.8198457	1.16592	0.71028	1.967641900	1.31660176960	24.04688926	Local fue mas rapido
Frecuencia de enfermedades y	0.64137693500	0.71407335500	0.58901	0.911835	0.5221398	0.89256	0.498382	1.6571873	1.22836223610	18.59078937	Local fue mas rapido
Mortalidad por enfermedad y	3.36328221799	4.296262734	3.297599	6.227906	3.1204154	3.53221	3.109953	4.366267300	1.07783156626	7.221125146	Local fue mas rapido
Mortalidad por estado	0.85529315400	0.82072167700	0.631181	0.975690	0.7308932	2.91445	0.682165	7.330296100	1.17020264241	14.54471526	Local fue mas rapido

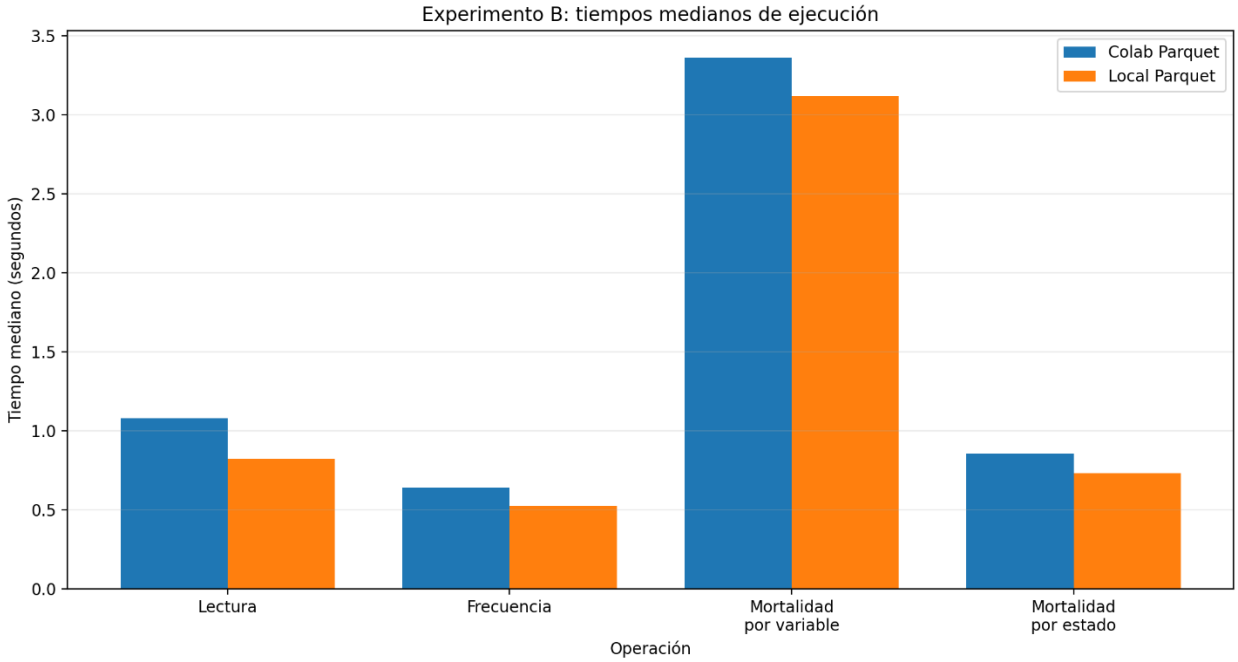
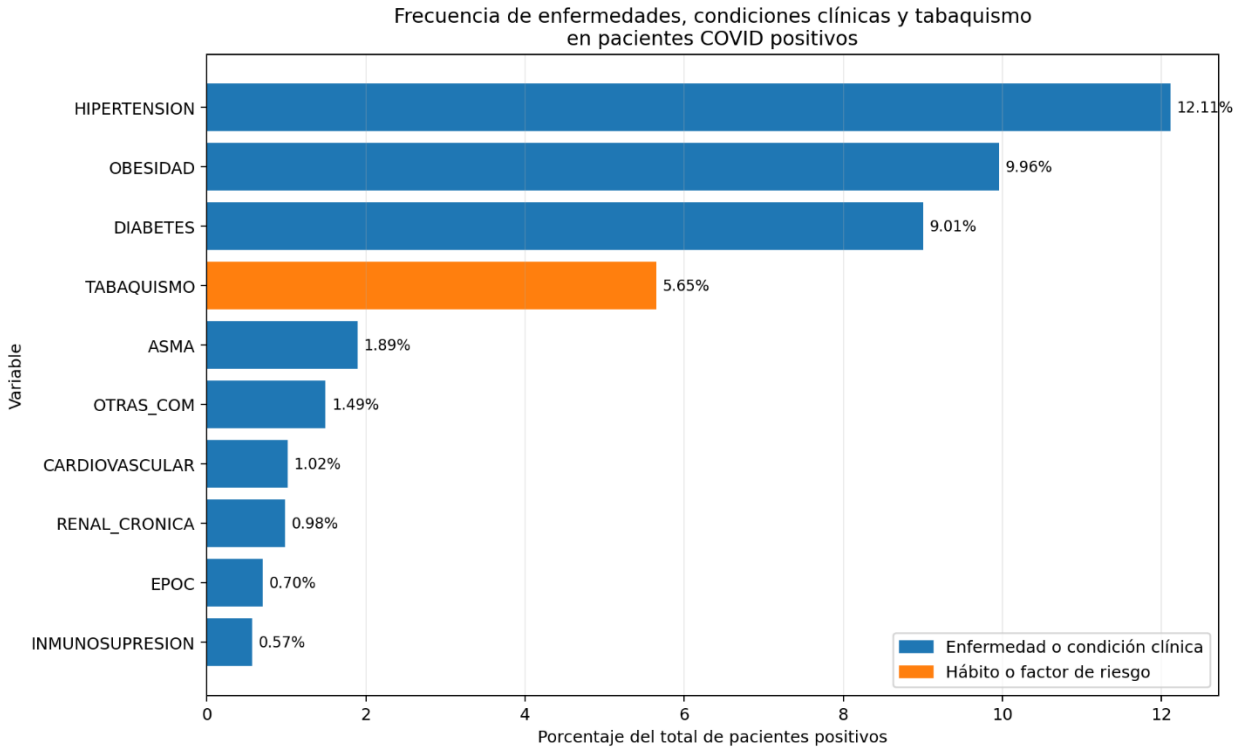


Figura 2 grafica tiempos recursos google y locales

4.3 Análisis de comorbilidades

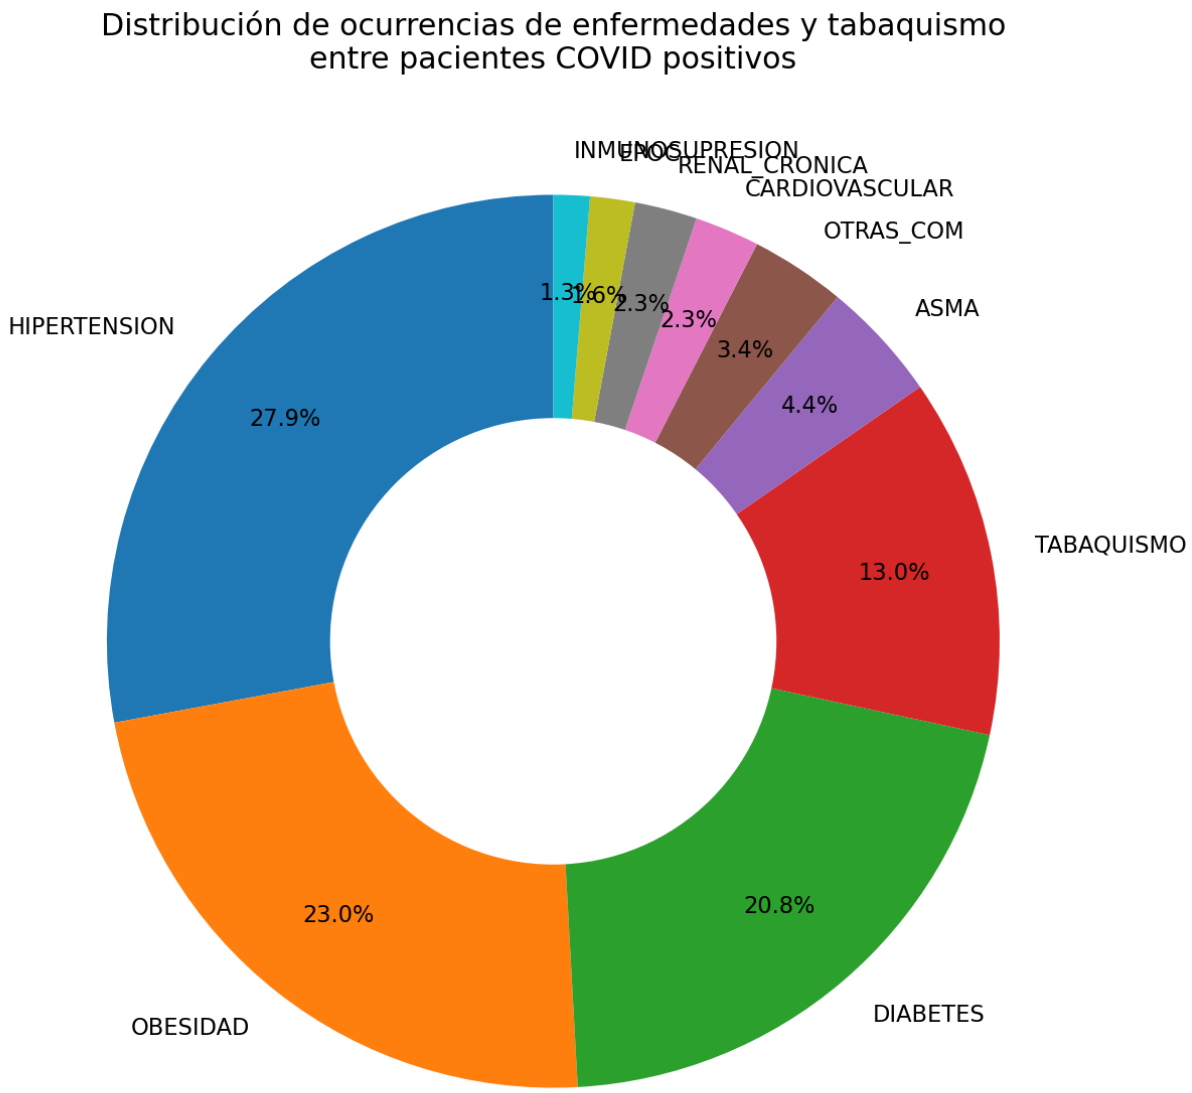
Frecuencia de enfermedades y tabaquismo

La hipertensión fue la condición registrada con mayor frecuencia entre los pacientes positivos a COVID-19, con 12.11 %, seguida de la obesidad con 9.96 % y la diabetes con 9.01 %. El tabaquismo estuvo presente en 5.65 % de los pacientes, mientras que la inmunosupresión, la EPOC y la enfermedad renal crónica presentaron las frecuencias más bajas. Estos porcentajes no son excluyentes, ya que un mismo paciente podía presentar más de una condición.



Distribución de ocurrencias de enfermedades y tabaquismo

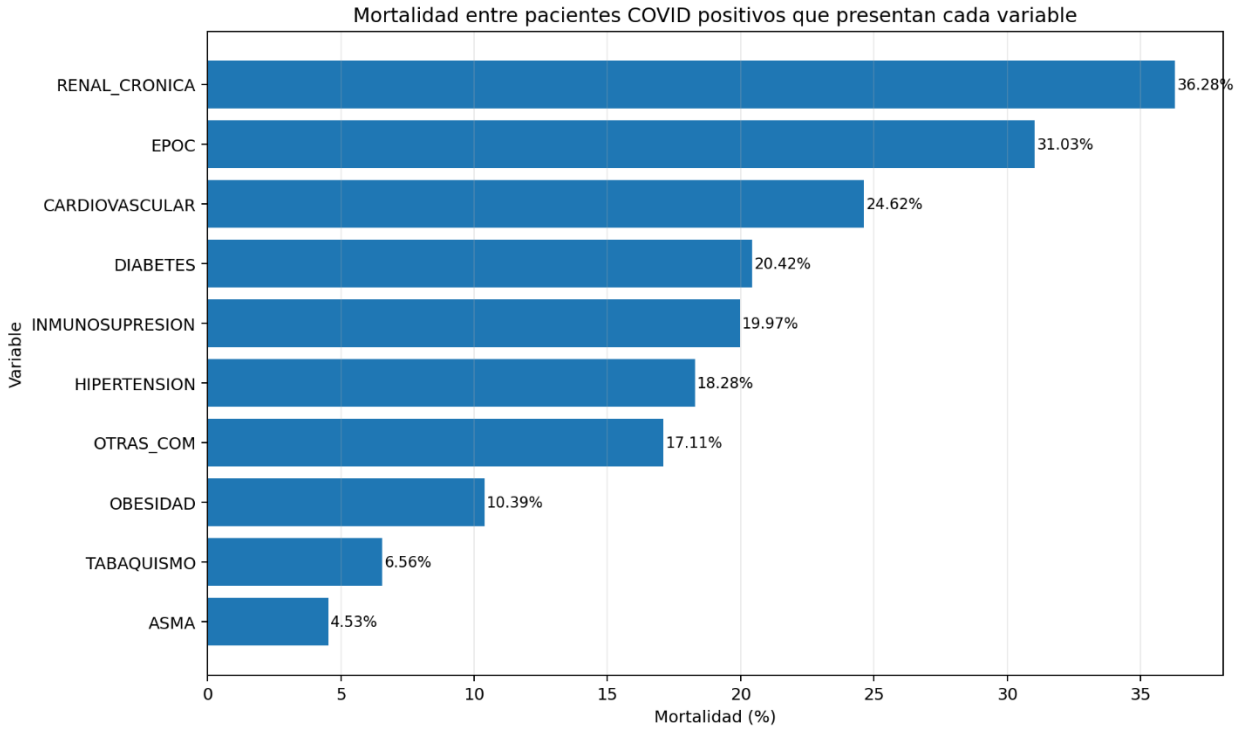
La hipertensión representó 27.9 % del total de condiciones registradas, seguida de la obesidad con 23.0 % y la diabetes con 20.8 %. El tabaquismo concentró 13.0 % de las ocurrencias. En conjunto, estas cuatro variables representaron la mayor parte de las enfermedades, condiciones clínicas y hábitos identificados entre los pacientes positivos.



Nota: un paciente puede presentar más de una condición; las porciones no son grupos exclusivos.

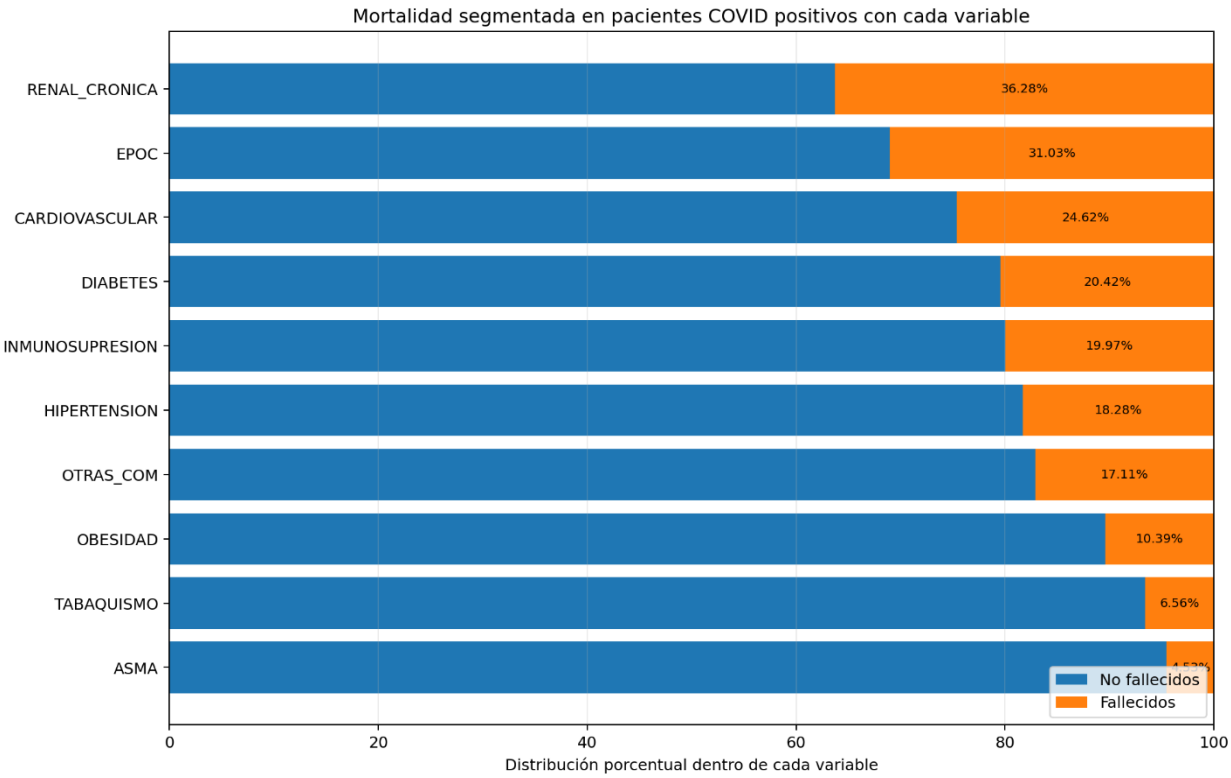
Proporción de fallecimientos por variable

La enfermedad renal crónica presentó la mayor proporción de fallecimientos, con 36.28 %, seguida de la EPOC con 31.03 % y las enfermedades cardiovasculares con 24.62 %. La diabetes y la inmunosupresión también presentaron valores cercanos al 20 %. En contraste, el asma registró la proporción más baja, con 4.53 %. Estos resultados muestran asociaciones descriptivas y no demuestran que una condición haya causado directamente el fallecimiento.



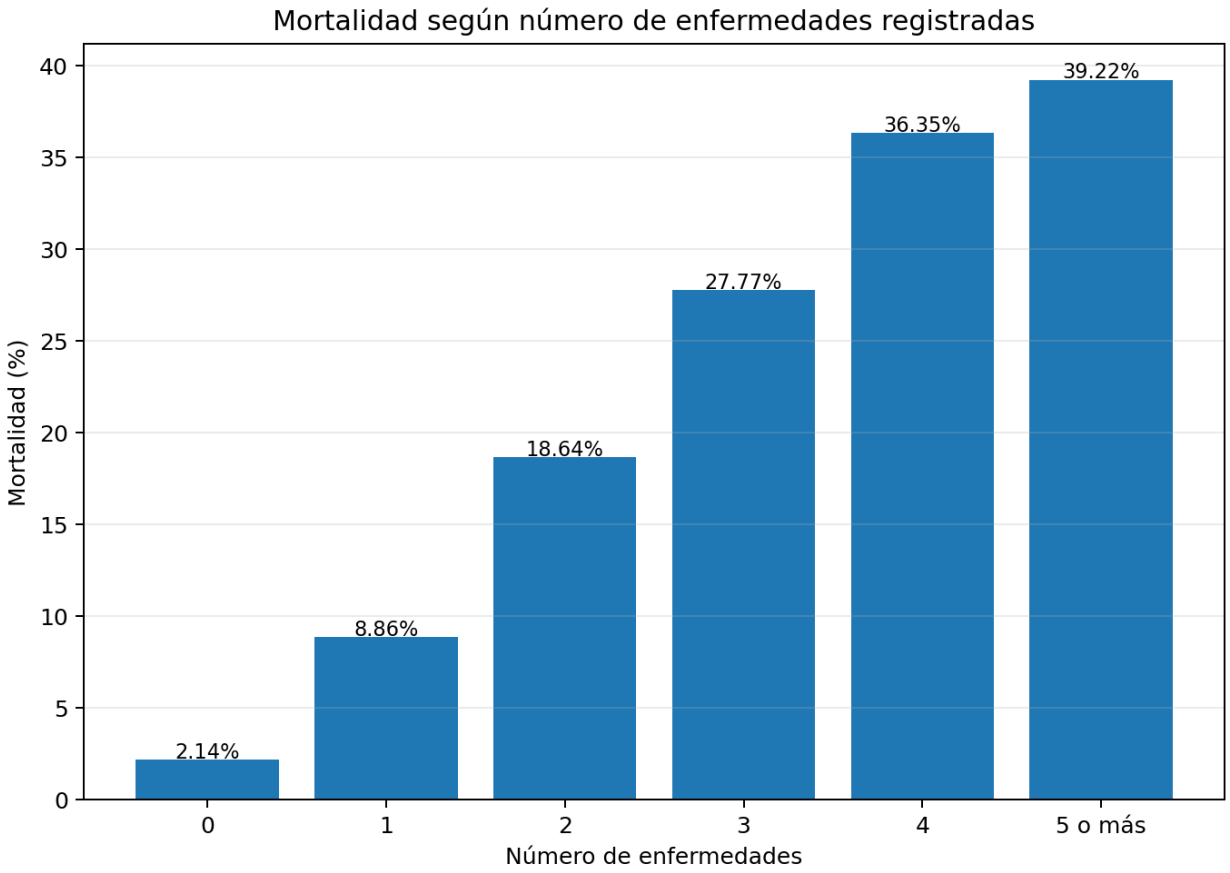
Mortalidad segmentada por variable

La gráfica segmentada muestra la proporción de pacientes fallecidos y no fallecidos dentro de cada condición. La enfermedad renal crónica y la EPOC presentaron las mayores participaciones de fallecimientos, con 36.28 % y 31.03 %, respectivamente. Por el contrario, en los pacientes con asma y tabaquismo más del 90 % no presentó una defunción registrada.



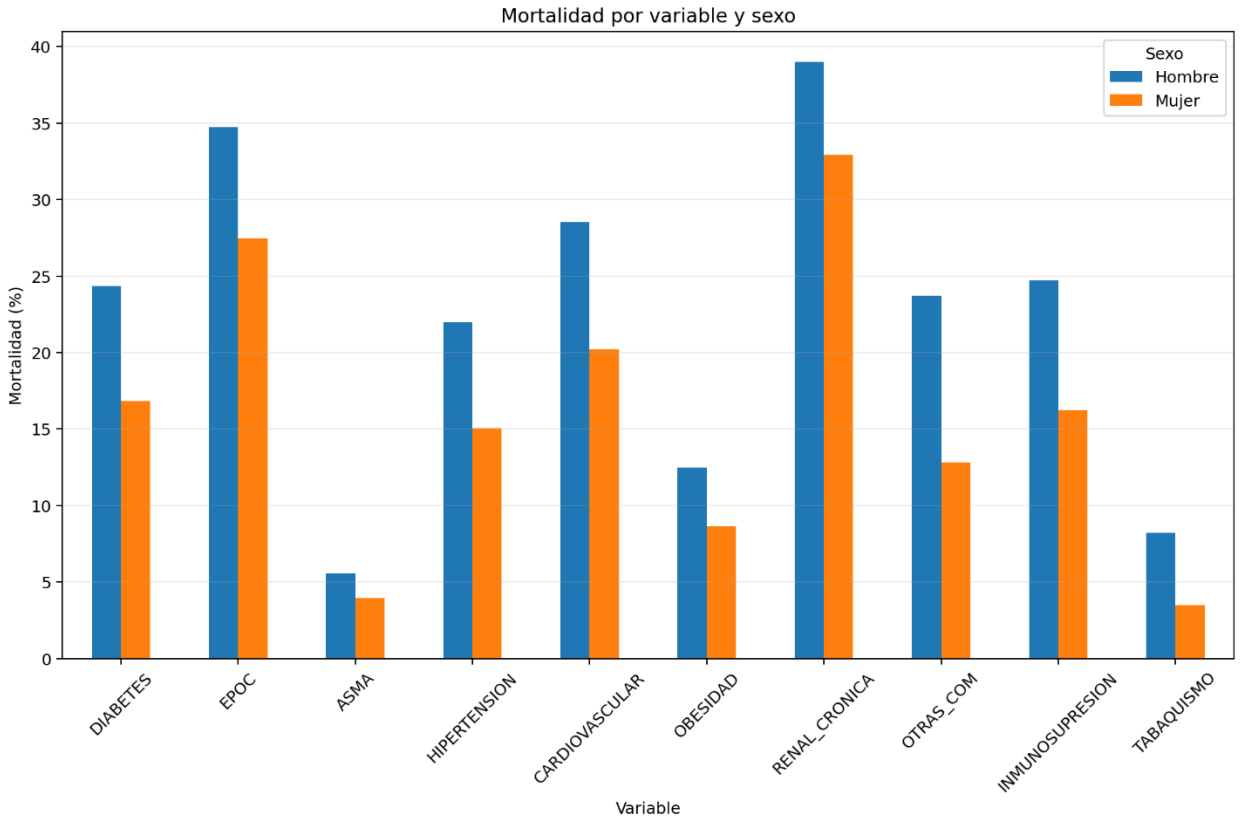
Mortalidad según el número de enfermedades

Se observó una tendencia ascendente en la proporción de fallecimientos conforme aumentó el número de enfermedades registradas. Los pacientes sin comorbilidades presentaron una proporción de 2.14 %, mientras que aquellos con una enfermedad alcanzaron 8.86 % y los que tenían tres enfermedades llegaron a 27.77 %. En los pacientes con cinco o más condiciones, la proporción aumentó hasta 39.22 %, lo que indica una asociación entre una mayor carga de comorbilidades y un desenlace desfavorable.



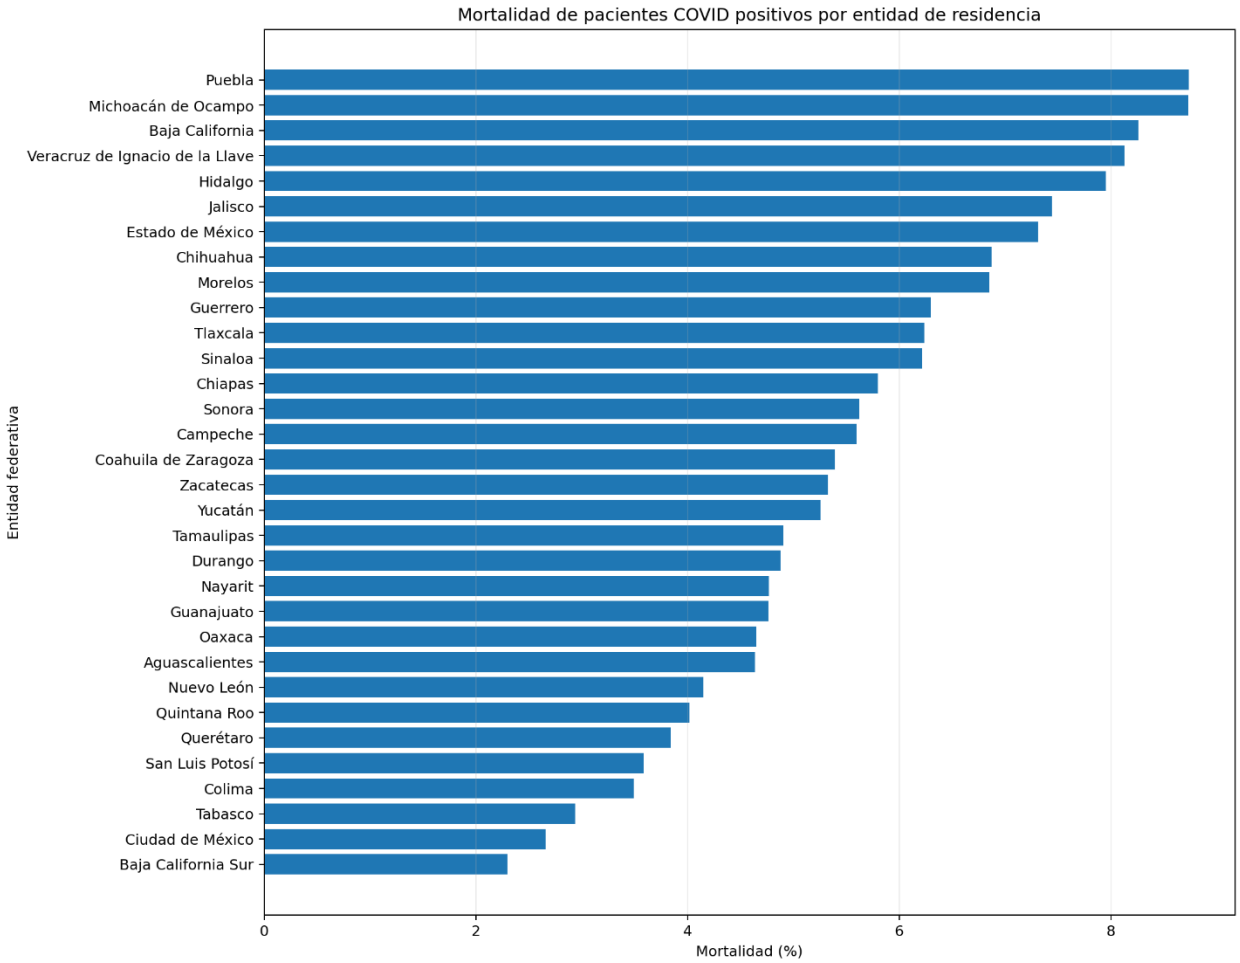
Mortalidad por variable y sexo

Los hombres presentaron una mayor proporción de fallecimientos que las mujeres en todas las variables analizadas. Las diferencias se observaron especialmente en la enfermedad renal crónica, la EPOC, las enfermedades cardiovasculares y la inmunosupresión. En ambos sexos, la enfermedad renal crónica y la EPOC fueron las condiciones con los valores más elevados, mientras que el asma y el tabaquismo mostraron los porcentajes más bajos.



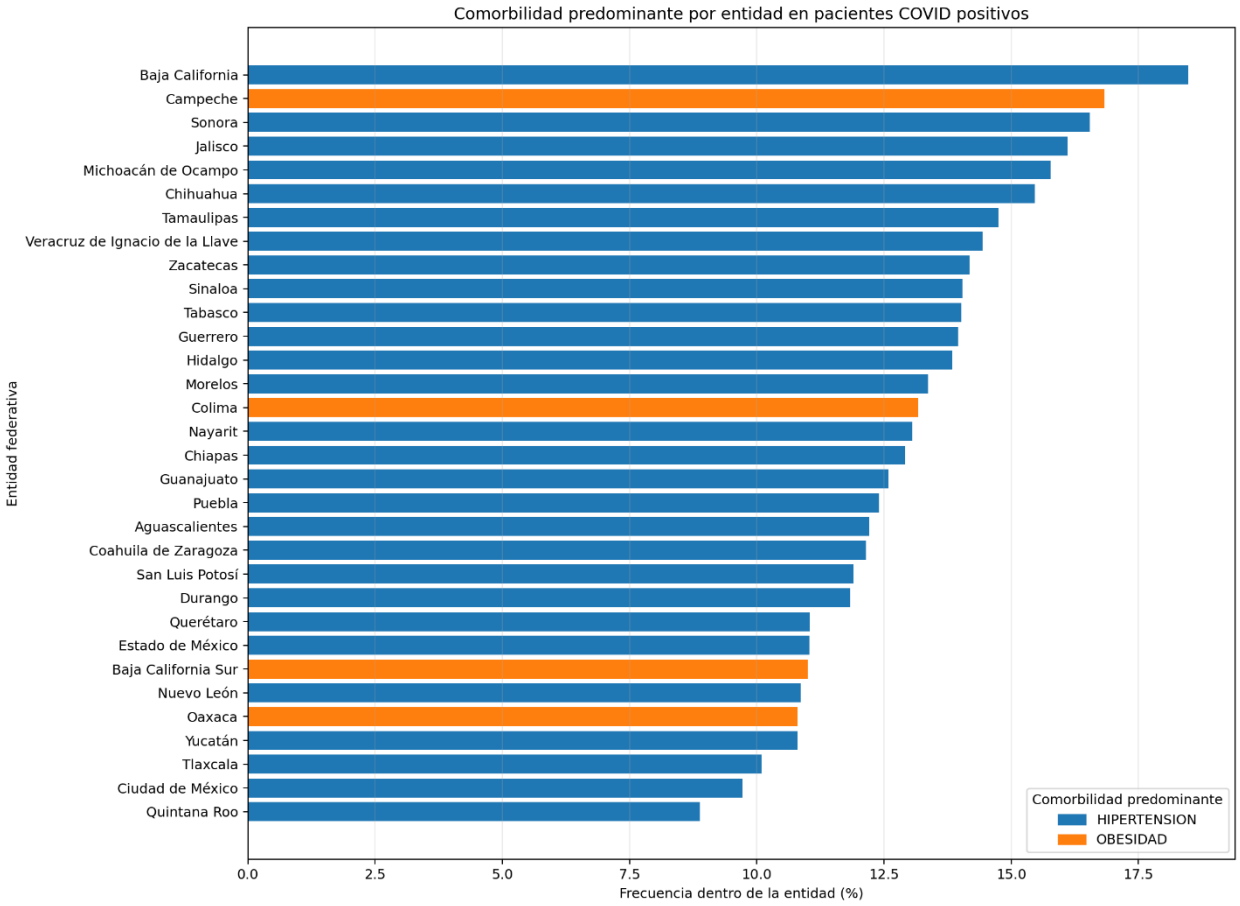
Mortalidad por entidad federativa

Puebla y Michoacán de Ocampo presentaron las mayores proporciones de fallecimientos entre los pacientes positivos, con valores cercanos al 8.7 %. También destacaron Baja California, Veracruz e Hidalgo con porcentajes superiores o cercanos al 8 %. En contraste, Baja California Sur, Ciudad de México y Tabasco registraron los valores más bajos. Estas diferencias pueden estar relacionadas con la composición de la población, la edad, las comorbilidades, la atención médica y las características del registro en cada entidad.



Comorbilidad predominante por entidad federativa

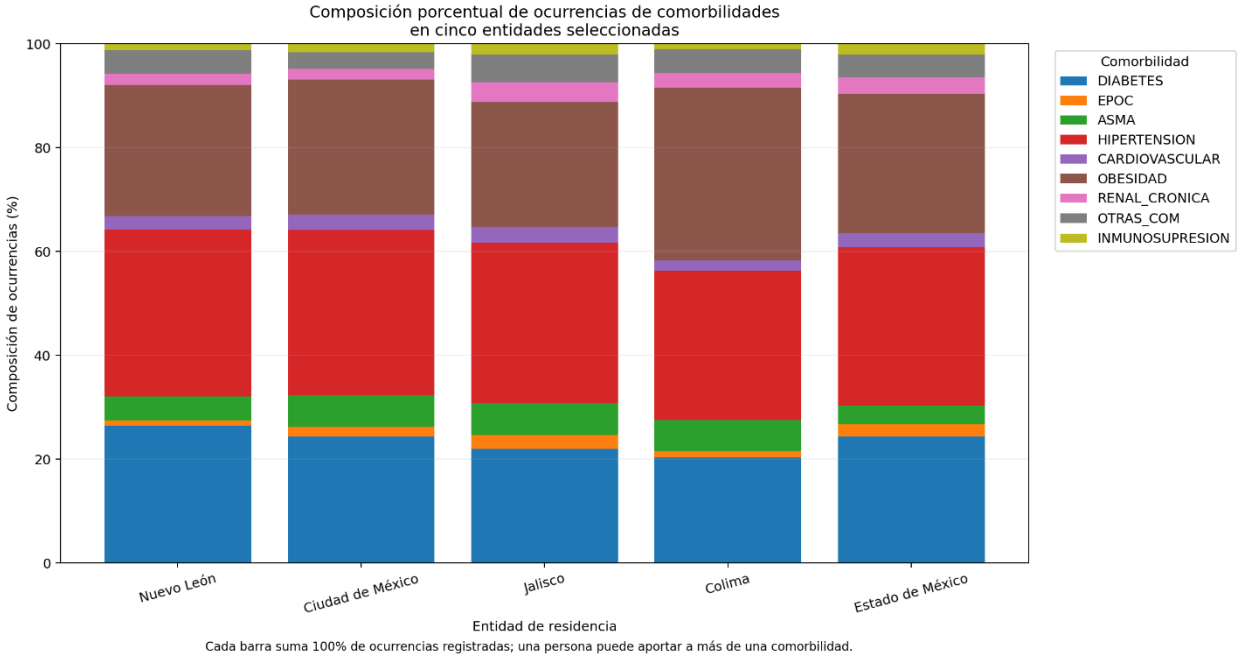
La hipertensión fue la comorbilidad predominante en la mayoría de las entidades federativas. Solamente en Campeche, Colima, Baja California Sur y Oaxaca la obesidad presentó una frecuencia mayor. Baja California mostró la proporción más alta de la condición predominante, mientras que Quintana Roo presentó una de las menores frecuencias relativas.



Comparación de cinco entidades federativas

Se seleccionaron Ciudad de México, Estado de México, Jalisco, Nuevo León y Colima para comparar su composición de comorbilidades.

Cada estado se representó mediante una barra segmentada normalizada al 100 %. Los segmentos de diferentes colores representan la participación de cada comorbilidad dentro del total de condiciones registradas en la entidad.



Conclusiones

El procesamiento del conjunto de datos permitió analizar más de 17 millones de registros y seleccionar 6,522,993 casos positivos de COVID-19.

La clasificación de las variables en comorbilidades y hábitos facilitó la identificación de las condiciones más frecuentes y el estudio de su relación con las defunciones registradas.

El análisis por comorbilidad permitió comparar la proporción de fallecidos y no fallecidos dentro de cada condición. El análisis por número de comorbilidades permitió estudiar el efecto asociado con la acumulación de enfermedades preexistentes. Por su parte, las comparaciones por entidad federativa y rango de edad permitieron observar diferencias geográficas y demográficas.

La conversión de CSV a Parquet permitió disponer de un conjunto de datos preparado para consultas analíticas. Los experimentos de rendimiento permitieron evaluar, de forma separada, el efecto del formato de almacenamiento y del entorno de ejecución.

Finalmente, la utilización de herramientas orientadas al procesamiento de grandes volúmenes de información permitió realizar el análisis de manera reproducible y con un uso más eficiente de los recursos computacionales.

https://www.gob.mx/salud/es/articulos/neumonia-enfermedad-que-afecta-los-pulmones